Lab5 实验报告

PB20000072 王铖潇

CPU

基础矩阵乘法，AVX矩阵乘法和AVX分块矩阵乘法的实现分别为`task1.cpp`，`task2.cpp`，`task3.cpp`.

三种实现性能的差异

对不同规模的输入，三种实现的矩阵乘法用时如下表。其中AVX分块矩阵乘法中块大小是$8*8$.

矩阵大小	基础矩阵乘法用时(s)	AVX矩阵乘法用时(s)	AVX分块矩阵乘法用时(s)
2^6*2^6	0.004380	0.000987	0.001000
2^8*2^8	0.1242	0.0374	0.0396
2^9*2^9	0.7840	0.1695	0.1913
$2^{10}*2^{10}$	14.0048	2.8428	1.9222
$2^{11}*2^{11}$	213.3354	36.8003	16.1930

对于64*64的矩阵，截图如下：

```
root@DESKTOP-CT70M52:/mnt/d/experiment_Vivado/Grade3_spring/Lab5/cpu# make
gcc -march=native -mavx task1.cpp -o task1
gcc -march=native -mavx task2.cpp -o task2
gcc -march=native -mavx task3.cpp -o task3
root@DESKTOP-CT70M52:/mnt/d/experiment_Vivado/Grade3_spring/Lab5/cpu# ./task1
矩阵乘法运行时间：0.124246秒
root@DESKTOP-CT70M52:/mnt/d/experiment_Vivado/Grade3_spring/Lab5/cpu# ./task2
AVX矩阵乘法运行时间：0.037364秒
root@DESKTOP-CT70M52:/mnt/d/experiment_Vivado/Grade3_spring/Lab5/cpu# ./task3
AVX分块矩阵乘法运行时间：0.039628秒
```

可以发现，使用AVX的两种方法性能明显好于基础矩阵乘法。但是AVX矩阵乘法和AVX分块矩阵乘法的性能和矩阵大小有关，当矩阵比较小的时候，AVX矩阵乘法和AVX分块矩阵乘法的性能相差不大，甚至AVX矩阵乘法的性能更好；但是矩阵规模较大的时候，AVX分块矩阵乘法的性能明显好于AVX矩阵乘法。

分析：使用AVX的方法性能明显好于基础的矩阵乘法是因为它们使用了并行化处理，可以大幅度缩短时间。AVX分块矩阵乘法虽然可以利用cache的局部性实现加速，但是分块的预处理本身也需要时间，所以当矩阵规模较小的时候，使用分块方法的优化效果并不明显，甚至可能由于预处理时间较长反而性能变差；但是当矩阵规模较大的时候，分块方法对cache局部性应用得更充分，有很明显的优化效果。

不同的分块参数对AVX分块矩阵乘法性能的影响

选择矩阵大小为$2^{10} * 2^{10}$，不同的分块参数下，矩阵乘法用时如下表：

块大小	用时(s)
$8 * 8$	1.6983
$16 * 16$	1.6645
$32 * 32$	1.4481
$64 * 64$	1.2247
$128 * 128$	1.4875
$256 * 256$	1.4520

可以发现，分块大小太小或者太大都会似的用时较长。

分块比较小的时候，可以充分利用cache的局部性，但循环次数较多，而每次循环前后都需要进行分块或是合并的处理。分块比较大的时候，不能很好地利用cache局部性。所以需要权衡二者，取一个合适的分块大小，才能获得更好的性能。

CPU平台上其它矩阵乘法的优化手段

1. 循环重排序

   调整三层循环中内两层循环的顺序，保证访问矩阵的空间局部性。

2. 循环展开

   直接对汇编生成的代码进行循环展开，减少流水线处理时的停顿。

3. 写缓存优化

   开一块write cache内存空间，每个block的计算结果直接在write cache上读写，最后计算完一个block之后，整块写回目标数组中对应的不同数组段上。

4. 算法优化

   对于较大规模的矩阵，优化算法、降低算法的时间复杂度也会对性能产生较大的提示。如Strassen算法或Winograd算法等。

GPU

基础矩阵乘法，分块矩阵乘法的实现分别为`task1.cpp`，`task2.cpp`.

两种实现性能的差异

对不同规模的输入，两种实现的矩阵乘法用时如下表。其中分块矩阵乘法中块大小是$8 * 8$.

矩阵大小	基础矩阵乘法用时(ms)	分块矩阵乘法用时(ms)
$2^6 * 2^6$	0.011136	0.007120
$2^8 * 2^8$	0.47824	0.27859
$2^9 * 2^9$	4.5099	2.6704
$2^{10} * 2^{10}$	35.948	21.688
$2^{11} * 2^{11}$	306.79	

矩阵大小为$2^6 * 2^6$时，使用`nvprof`工具对矩阵乘法kernel的时间进行profiling，截图如下：

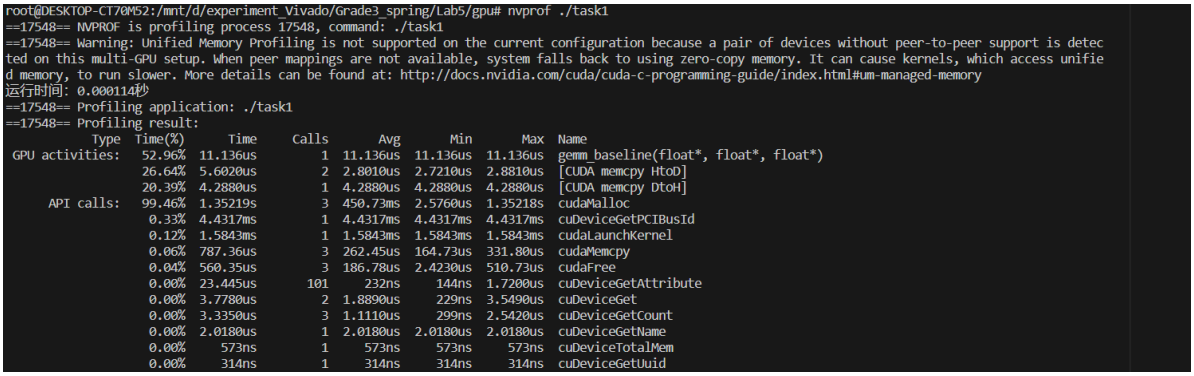

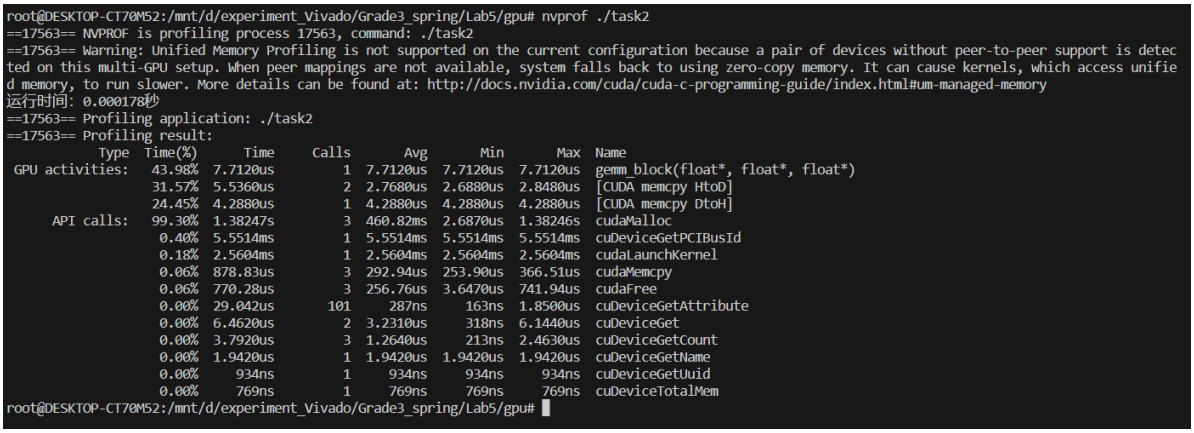

GPU上，分块矩阵乘法用时短于基础矩阵乘法。

这是因为分块矩阵乘法利用了访存更快的`shared memory`，效率更高。

不同的`gridsize`和`blocksize`对基础矩阵乘法性能的影响

`gridsize`根据`blocksize`而变化。这里改变`blocksize`，对性能的影响如下表。矩阵规模是$64 * 64$.

blocksize	用时(us)
$4 * 4$	1234.6
$8 * 8$	710.05
$16 * 16$	480.04
$32 * 32$	493.96

`blocksize`为$8 * 8$的时候，使用`nvprof`工具对矩阵乘法kernel的时间进行profiling，截图如下：

```
root@DESKTOP-CT70M52:/mnt/d/experiment_Vivado/Grade3_spring/Lab5/gpu# nvprof ./task1
==18238== NVPROF is profiling process 18238, command: ./task1
==18238== Warning: Unified Memory Profiling is not supported on the current configuration because a pair of devices without peer-to-peer support is detec
ted on this multi-GPU setup. When peer mappings are not available, system falls back to using zero-copy memory. It can cause kernels, which access unifie
d memory, to run slower. More details can be found at: http://docs.nvidia.com/cuda/cuda-c-programming-guide/index.html#um-managed-memory
运行时间: 0.000345秒
^C==18238== Profiling application: ./task1
==18238== Profiling result:
            Type  Time(%)      Time     Calls       Avg       Min       Max  Name
 GPU activities:   94.64%  491.62ms         1  491.62ms  491.62ms  491.62ms  gemm_baseline(float*, float*, float*)
                    3.44%  17.882ms         2  8.9410ms  6.9377ms  10.944ms  [CUDA memcpy HtoD]
                    1.92%  9.9508ms         1  9.9508ms  9.9508ms  9.9508ms  [CUDA memcpy DtoH]
      API calls:   79.50%  2.05136s         3  683.79ms  722.29us  2.04990s  cudaMalloc
                   20.07%  517.85ms         3  172.62ms  7.1846ms  502.95ms  cudaMemcpy
                    0.31%  7.9631ms         1  7.9631ms  7.9631ms  7.9631ms  cuDeviceGetPCIBusId
                    0.12%  3.1946ms         1  3.1946ms  3.1946ms  3.1946ms  cudaLaunchKernel
                    0.00%  58.913us       101     583ns     307ns  3.2190us  cuDeviceGetAttribute
                    0.00%  6.0300us         3  2.0100us     587ns  4.6700us  cuDeviceGetCount
                    0.00%  5.7550us         2  2.8770us     638ns  5.1170us  cuDeviceGet
                    0.00%  2.7690us         1  2.7690us  2.7690us  2.7690us  cuDeviceGetName
                    0.00%  1.0260us         1  1.0260us  1.0260us  1.0260us  cuDeviceTotalMem
                    0.00%     754ns         1     754ns     754ns     754ns  cuDeviceGetUuid
```

可以看出，`blocksize`过小或是过大都会对性能产生负面影响。

`blocksize`增加时，一方面增加了一次性处理的数据数量，但另一方面也可能超出硬件设备支持的范畴，导致部分操作退化为串行处理从而导致性能下降。所以需要权衡，找到一个合适的`blocksize`.

不同的`gridsize`和`blocksize`对分块矩阵乘法性能的影响

`gridsize`根据`blocksize`而变化。这里改变`blocksize`，对性能的影响如下表。矩阵规模是$64 * 64$.

blocksize	用时(us)
$4 * 4$	1064.2
$8 * 8$	278.02
$16 * 16$	233.73
$32 * 32$	227.52

`Block`大小为$8 * 8$的时候，使用`nvprof`工具对矩阵乘法kernel的时间进行profiling，截图如下：

```
root@DESKTOP-CT70M52:/mnt/d/experiment_Vivado/Grade3_spring/Lab5/gpu# make
nvcc  task1.cu -o task1
nvcc  task2.cu -o task2
root@DESKTOP-CT70M52:/mnt/d/experiment_Vivado/Grade3_spring/Lab5/gpu# nvprof ./task2
==18806== NVPROF is profiling process 18806, command: ./task2
==18806== Warning: Unified Memory Profiling is not supported on the current configuration because a pair of devices without peer-to-peer support is detec
ted on this multi-GPU setup. When peer mappings are not available, system falls back to using zero-copy memory. It can cause kernels, which access unifie
d memory, to run slower. More details can be found at: http://docs.nvidia.com/cuda/cuda-c-programming-guide/index.html#um-managed-memory
运行时间: 0.000277秒
==18806== Profiling application: ./task2
==18806== Profiling result:
            Type  Time(%)      Time     Calls       Avg       Min       Max  Name
 GPU activities:   78.57%  1.0642ms         1  1.0642ms  1.0642ms  1.0642ms  gemm_block(float*, float*, float*)
                   15.57%  210.95us         2  105.47us  84.737us  126.21us  [CUDA memcpy HtoD]
                    5.86%  79.329us         1  79.329us  79.329us  79.329us  [CUDA memcpy DtoH]
      API calls:   98.95%  1.42454s         3  474.85ms  4.6080us  1.42452s  cudaMalloc
                    0.54%  7.8119ms         1  7.8119ms  7.8119ms  7.8119ms  cuDeviceGetPCIBusId
                    0.24%  3.4703ms         1  3.4703ms  3.4703ms  3.4703ms  cudaLaunchKernel
                    0.19%  2.7909ms         3  930.29us  434.31us  1.8078ms  cudaMemcpy
                    0.07%  963.90us         3  321.30us  2.9880us  869.18us  cudaFree
                    0.00%  48.080us       101     476ns     322ns  1.9690us  cuDeviceGetAttribute
                    0.00%  5.4180us         2  2.7090us     399ns  5.0190us  cuDeviceGet
                    0.00%  3.2610us         3  1.0870us     277ns  2.2930us  cuDeviceGetCount
                    0.00%  2.2380us         1  2.2380us  2.2380us  2.2380us  cuDeviceGetName
                    0.00%     963ns         1     963ns     963ns     963ns  cuDeviceTotalMem
                    0.00%     625ns         1     625ns     625ns     625ns  cuDeviceGetUuid
```

可以看出，`BLOCK`的大小增加时性能上升。

可能是因为BLOCK大小增加时，分块后一次性处理的数据更多，减少了每次分块前后的处理时间。